A-CSM：AI Contextual Signal Matrix

公開安全核心 v0.1.0 技術報告

以互動後對話紀錄為基礎之對話語境風險審查

作者： ZON RZVN
身分： Independent Researcher, Taiwan

版本： Technical Report v1.0
文件日期： 2026-03-18
專案頁面： https://rzvn.io/a-csm
倉庫： https://github.com/kyozong77/A-CSM
預留 DOI： 10.5281/zenodo.19097267

報告授權： CC BY-NC-ND 4.0

倉庫範圍： GitHub 公開安全核心候選版 v0.1.0

範圍聲明。本報告僅涵蓋 GitHub 上傳資料夾中 v0.1.0 已釋出的公開核心實作。本文說明的是一套在對話互動紀錄形成之後，用於辨識對話語境風險的可執行系統。未公開或受限制的組件，不在本文討論範圍內。

Abstract

A-CSM 的正式全名為 *AI Contextual Signal Matrix*。已釋出的公開核心是一套具決定性的 Node.js 管線，用於在對話互動完成之後，對對話語境風險進行審查。它的功能比即時內容管制更聚焦，主要用於可重現的基線驗證、釋出審查、紅隊測試支援，以及互動後的技術檢查。

本報告僅記錄公開核心版本，也就是 `v0.1.0`。本文範圍只限於 GitHub 上傳資料夾內實際存在的內容，包括輸入格式、各處理階段、已釋出的設定介面、輸出契約、驗證路徑，以及目前的公開邊界。未公開或受限制的組件，不在本文討論範圍內。

目前公開核心支援結構化 `turns` 輸入、頂層 `text` 快捷輸入，以及 Markdown 逐字稿輸入。系統會經過一條已釋出的八階段協調流程，涵蓋去識別化、事件偵測、VCD 推論、重複訊號登錄、TAG 升級判定、`PS/SUB/F/E` 推導、schema 驗證與 release gate 評估。以 2026-03-18 的驗證套件為基準，本地測試結果為 `921` 項通過、`0` 項失敗；已釋出的 baseline run 則記錄 `accuracy = 1.0`、`false_positive_rate = 0`、`false_negative_rate = 0`，對應於目前公開的 risk-status 基線切片。

本報告有四個目的。第一，交代 A-CSM 的正式名稱、範圍與公開邊界。第二，說明公開核心如何運作以及應如何執行。第三，界定目前驗證結果實際能證明與不能證明的範圍。第四，在不超出已釋出內容的前提下，說明 A-CSM 與 CXC-7、CXOD-7、USCH 以及 Moore et al. 經驗證據之間的關係。

關鍵詞：對話語境風險、公開安全釋出、決定性管線、逐字稿審查、互動後評估、A-CSM

Contents

1 導論 **2**

2 公開定位與發表邊界 **2**

2.1 正式名稱與發表身分 2

2.2 公開核心包含的內容 2

2.3 公開核心不包含的內容 2

3 系統範圍與核心主張 **3**

3.1 問題定義 3

3.2 已釋出版的設計原則 3

3.3 本報告的限制 4

4 架構與執行路徑 **4**

4.1 輸入面 4

4.2 八個已釋出的 stages 4

4.3 輸出契約 5

5 操作流程 **5**

5.1 環境與執行需求 5

5.2 驗證流程 6
5.3 端到端執行 6
5.4 審查者應檢查的重點 7

6 `v0.1.0` 的目前驗證狀態 7
6.1 倉庫層級驗證結果 7
6.2 這份證據能證明什麼 8
6.3 這份證據不能證明什麼 8

7 與前作和外部經驗證據的關係 8
7.1 研究脈絡 8
7.2 Moore et al. 的經驗意義 9
7.3 較廣的風險與治理脈絡 9

8 限制與下一版本方向 9

9 結論 10

A 代表性指令 10

B 參考文獻 10

1. 導論

當前對對話式 AI 安全的討論，常以單一輸出為核心。這種視角對拒答行為、有害內容過濾與政策遵循很重要，但它無法完整捕捉沿著互動歷史逐步累積的風險。在多輪互動中，一段對話即使表面上仍然合理，也可能在使用者端安全、語境對齊與系統責任上持續偏移。

公開版 A-CSM 正是為了處理這個較窄、但技術上重要的問題。它不介入生成當下，而是在對話互動紀錄已經存在之後，對整份對話進行審查。專案頁面沿用相同的正式名稱，並將 A-CSM 呈現為此一研究脈絡下、與風險審查相關的公開釋出項目。[1] 因此，本文將 `v0.1.0` 視為一項可公開驗證的實作成果。

本報告僅以 GitHub 上傳資料夾中的公開核心內容為基礎，不延伸到未來版本或未公開組件。所有主張都只根據目前可檢查的公開內容提出。

2. 公開定位與發表邊界

2.1 正式名稱與發表身分

本次系統的正式名稱為 **A-CSM：AI Contextual Signal Matrix**。倉庫 README 亦以此命名，並將其定義為一套具決定性的 Node.js 管線，用於評估與 factual reliability、context alignment、user-side safety 及 system accountability 相關的對話風險。

這個公開身分很重要，因為它決定了報告可以主張到哪裡。對本次技術報告而言，`v0.1.0` 是一套邊界明確、功能收斂的已釋出系統，其核心功能是對公開核心套件中的互動後對話語境風險進行審查。

2.2 公開核心包含的內容

目前 GitHub 上傳資料夾內包含：

- 以 `scripts/acsm-orchestrator.mjs` 為核心的 Node.js ES module runtime；
- 已釋出的 configuration files 與 sample inputs；
- deterministic transcript processing 與 report generation；
- validation、regression 與 release-gate 相關腳本；
- orchestrator、validation framework、annotation workflow、limitations 與 public claims 邊界文件；
- 可以在本地重跑的 public baseline package。

2.3 公開核心不包含的內容

同一條 release boundary 也明確排除了：

- 保密的內部分類體系；

[1] https://rzvn.io/a-csm

- 未公開的評估準則；
- private real-world holdout assets；
- 未公開的決策程序；
- runtime intervention systems；
- clinical 或 legal decision functions。

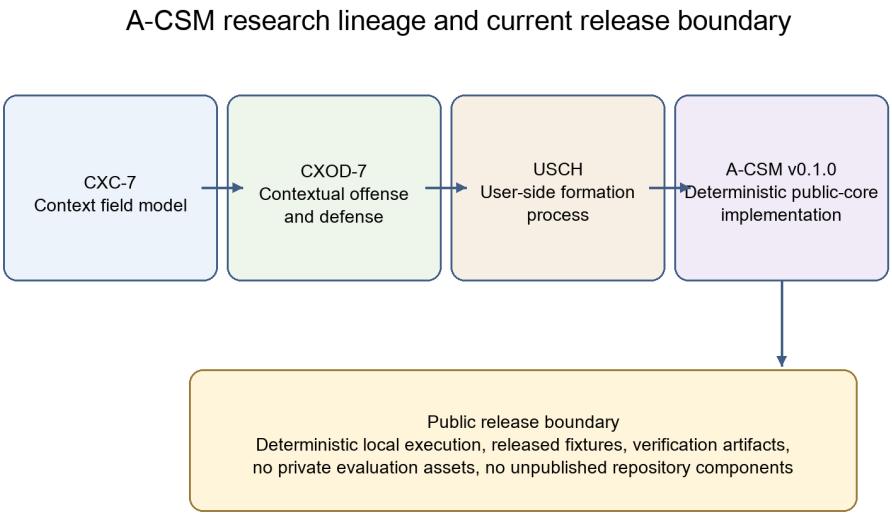

Figure 1: A-CSM 的研究脈絡與目前公開釋出邊界。

3. 系統範圍與核心主張

3.1 問題定義

在目前公開分支中，A-CSM 是一套互動後審查系統。它接收一份已完成的對話互動紀錄，並輸出一份結構化審查結果。本次釋出處理的是對話語境風險，而不是孤立文字的毒性判斷，也不是只為基準測試服務的性能展示。這也是為什麼公開版的輸入、軌跡與輸出都圍繞整份對話紀錄組織，而不是單一句子。

3.2 已釋出版的設計原則

公開核心可以從五個原則理解：

1. **決定性**。同一份輸入與設定應得到同一份結果。
2. **本地執行**。已釋出的評分路徑不依賴外部執行服務。
3. **可稽核性**。輸出保留證據軌跡與各階段產物。
4. **保守的釋出紀律**。對外主張只限於目前公開分支可證明的範圍。
5. **人類審查**。系統支援 review 與 escalation，不取代專業判斷。

3.3 本報告的限制

本文只處理目前桌面上 GitHub 上傳資料夾中的公開內容，不延伸到未來版本或未公開組件。本文的目的，是為目前的公開核心版本留下可核對的技術報告。

4. 架構與執行路徑

4.1 輸入面

公開版 orchestrator 支援三種輸入形式：

- **`turns` 模式**，直接輸入結構化的 JSON 對話輪次；
- **`text` 快捷模式**，以頂層文字輸入並正規化為單輪對話；
- **Markdown 逐字稿模式**，透過 `input-contract` 將 `.md` 或 `.markdown` 檔轉為穩定的對話輪次後再進入評分流程。

這裡必須區分清楚：`input-contract` 是 Markdown 輸入的前處理邊界，不是八個協調階段之一。

4.2 八個已釋出的 stages

依據公開 orchestrator 文件，目前公開版定義的八階段流程如下：

1. De-identify transcript content（`deid-pipeline`）
2. Detect four-axis risk events（`event-engine-v1`）
3. Infer VCD defense posture（`vcd-inference`）
4. Build repeat-aware ledgers（`ledger-repeat-engine`）
5. Compute TAG escalation level（`tag-escalation`）
6. Derive `PS/SUB/F/E`（`ps-sub-fe-core`）
7. Validate USCI schema and invariants（`schema-invariant-service`）
8. Evaluate release gate readiness（`release-gate`）

目前公開引擎清單包含 43 條事件偵測規則，以及一組含有 20 條規則的 VCD 矩陣。實際的設定介面則以對應表、門檻值與規則開關為主，用來控制已釋出引擎的套用方式。

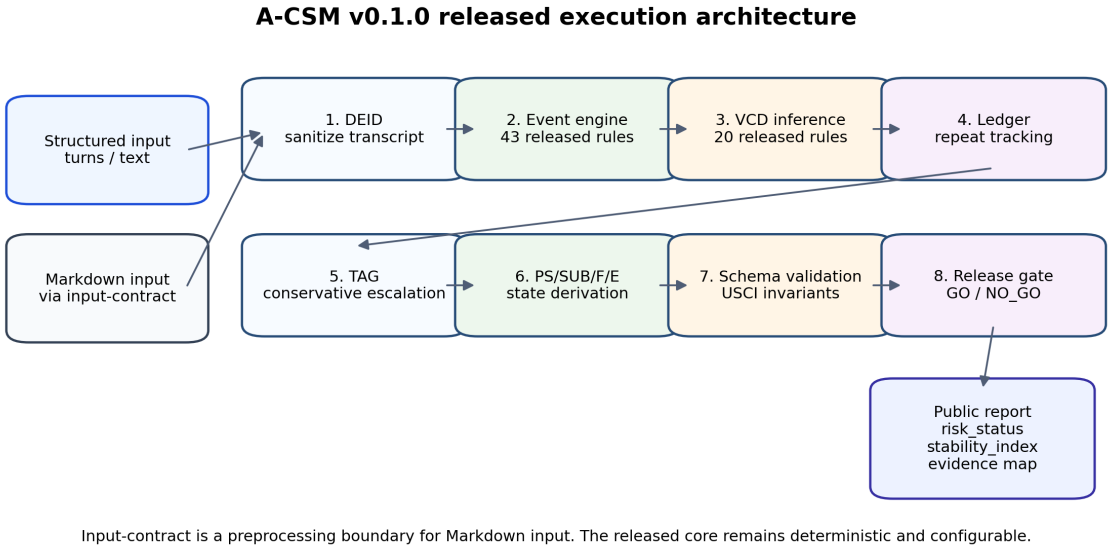

Figure 2: 公開核心 `v0.1.0` 的已釋出架構。

4.3 輸出契約

公開 report block 目前包含十個必要欄位：

欄位	公開版用途
`risk_status`	最終操作狀態
`peak_status`	執行過程中到達的最高嚴重度
`stability_index`	0–100 的正規化穩定度分數
`evidence_list`	依序排列的證據項目
`false_positive_warnings`	各階段累積的非阻斷警示
`human_review_note`	強制保留的人類審查提醒
`event_evidence_map`	事件對證據的可追溯結構
`confidence_interval`	0–4 風險刻度上的區間結果
`digital_fingerprint`	去識別內容與衍生報告的 SHA-256 指紋
`rule_version`	評估所使用的 schema 與規則版本資訊

除 report block 外，orchestrator 也會保留 `summary`、`steps` 與 `derived` 等技術追蹤結構，以便重跑與檢查。

5. 操作流程

5.1 環境與執行需求

公開套件要求 `Node >= 20`。已釋出的評分路徑採本地優先設計，不依賴外部執行服務。倉庫中附帶的 Python 工具僅屬輔助性研究工具，並不是執行核心 orchestrator 的必要條件。

5.2 驗證流程

依據 README 與驗證備忘錄，公開核心的基本驗證流程如下：

```
npm run lint:syntax
npm test
npm run test:coverage
npm run performance:baseline
npm run security:scan
npm run audit:workspace
```

這些指令分別對應語法檢查、Node.js 測試、覆蓋率執行、已釋出的效能基線、敏感資訊掃描與工作區狀態檢查。

若只需要重現 Markdown 逐字稿正規化，倉庫另提供獨立的 input-contract 入口：

```
npm run input:check -- \
  --input config/input-contract-input.sample.md \
  --config config/input-contract-config.sample.yaml \
  --output logs/input-contract-result.json \
  --format both
```

5.3 端到端執行

JSON sample path 可使用：

```
npm run acsm:run -- \
  --input config/acsm-orchestrator-input.sample.json \
  --config config/acsm-orchestrator.json \
  --validation config/validation-runner-result.sample.json \
  --output logs/acsm-orchestrator-result.json \
  --format both
```

Markdown transcript path 則為：

```
npm run acsm:run -- \
  --input config/input-contract-input.sample.md \
  --config config/acsm-orchestrator.json \
  --output logs/acsm-orchestrator-from-md.json \
  --format both
```

公開版也包含 batch 與 regression 路徑：

```
npm run acsm:run:200
npm run regression:check
```

5.4 審查者應檢查的重點

就目前公開分支而言，審查者至少應確認四件事：

- 執行流程能在沒有 runtime 或 schema failure 的情況下完成；
- summary 有揭露 release gate 與 validation signals；
- report block 完整包含已釋出的欄位；
- 各階段軌跡可被保留，以供重新檢查。

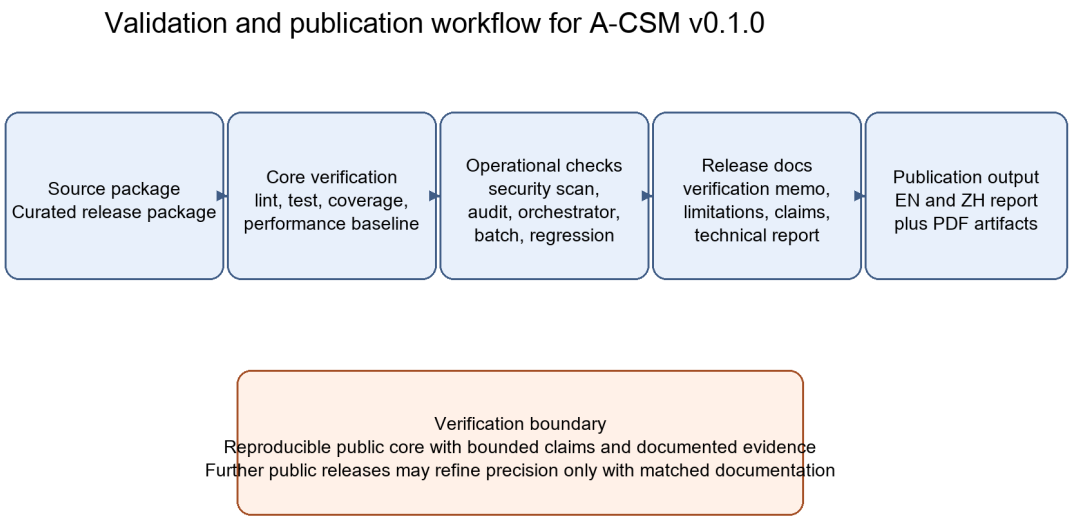

Figure 3: 公開核心的驗證與發表流程。

6. `v0.1.0` 的目前驗證狀態

6.1 倉庫層級驗證結果

2026-03-18 的驗證備忘錄記錄了以下本地結果：

Table 2: 目前倉庫層級驗證結果

檢查項目	已記錄結果
`npm test`	`921 pass / 0 fail`，共 41 個測試套件
`npm run test:coverage`	通過
`npm run performance:baseline`	通過，readiness 為 ready
`npm run security:scan`	未發現 secrets
`npm run audit:workspace`	READY
`npm run acsm:run`	通過
`npm run acsm:run:200`	通過
`npm run regression:check`	通過

已釋出的效能基線檔案另記錄：

- `total_cases = 100`
- `exact_matches = 100`
- `accuracy = 1.0`
- `false_positive_rate = 0`
- `false_negative_rate = 0`

在目前腳本中，`exact_matches` 的計算基準是每一個 baseline case 的 `risk_status` 是否一致，因此它應被理解為已釋出 risk-status 基線切片上的完整一致，而不是所有下游欄位都完全相同。

6.2 這份證據能證明什麼

目前公開套件能支持以下主張：

- 已釋出的核心可以在本地重跑；
- 目前公開分支提供穩定的協調流程；
- 倉庫包含可公開重現的驗證路徑；
- 目前基線切片在已釋出判定層級上具備內部一致性。

6.3 這份證據不能證明什麼

同一批證據不能證明：

- 臨床效度；
- 外部泛化能力；
- 相對其他系統的優越性；
- 非公開評估材料上的表現；
- 無人監督即時部署的適用性。

7. 與前作和外部經驗證據的關係

7.1 研究脈絡

公開 README 將 A-CSM 放在一條研究脈絡之後，包括 CXC-7、CXOD-7、USCH，以及 USCI 的互動後評估方法 [10]。對本報告而言，重點不是重寫這些框架，而是確認目前公開分支與這些前作在方法上是一致的：都重視語境、多輪互動，以及使用者端風險形成。

CXC-7 提供對話語境的場域模型 [3]。CXOD-7 從 system-facing 的角度處理語境中的攻防問題 [4]。USCH 則將分析重心移向分階段的使用者端語境形成 [9]。A-CSM 在目前公開分支中的角色，是將這些觀點收斂為一條已釋出的實作管線。

7.2 Moore et al. 的經驗意義

Moore et al. 透過 human-LLM 對話紀錄說明逐字稿層級的證據為何重要 [7]。其中三點特別與目前公開分支有關：

- 研究使用 28 項代碼清單，而不是單一傷害標籤；
- chatbot 將自己表述為具感知能力的情形，出現在 21.2% 的 chatbot 訊息中；
- 在妄想性對話中，assistant 訊息裡的迎合性標記超過 80%。

這些結果本身不等於對公開核心的直接驗證，但它們支持了一個核心設計決策：對話風險的審查必須把 transcript history、recurrence 與 evidence linkage 納入基本結構。在本報告中，這些數據只作為外部經驗動機，不作為 v0.1.0 的直接驗證資料。

Empirical bridge from Moore et al. (2026) to A-CSM design

Moore et al. (2026)	Conceptual bridge	A-CSM design target
bot misrepresents sentience 21.2% of chatbot messages	USCH: anthropomorphism, memory continuity illusion	Preserve context-linked evidence instead of isolated error labels
sycophancy >80% in assistant messages	CXOD-7: role, personality, safety calibration gaps	Separate event, VCD, ledger, and escalation stages
relationship-elevating content in longer chats	CXC-7: attachment, framing, boundary movement	Treat transcript history as the unit of review
violent and self-harm disclosure patterns	User-side safety as a distinct risk axis	Require explicit human-review note and traceability

Figure 4: 外部經驗證據與公開核心設計目標之間的對接。

7.3 較廣的風險與治理脈絡

Chandra et al. 用較結構化的方式整理了 AI 對話代理可能帶來的心理風險 [2]。Au Yeung et al. 則指出，若互動處於心理高壓或妄想強化情境，單靠良性任務評估並不足夠 [1]。而 NIST AI RMF、ISO/IEC 42001 與 EU AI Act 所對應的，是一種以風險管理為核心的文件治理姿態，而不是缺乏證據支撐的認證宣稱 [8, 6, 5]。這也正是公開核心版目前採取的做法。

8. 限制與下一版本方向

目前公開核心有四項清楚限制：

1. 公開的證據面仍以合成資料為主；
2. 目前公開分支採保守且具決定性的設計，利於稽核，但不提供未公開的細緻語意判定；

3. 本次釋出不包含私有保留評估資料或任何未公開決策程序；
4. 本次釋出是互動後審查系統，不是即時介入服務。

這些限制界定了目前版本可以被負責任地主張的範圍。對 `v0.1.0` 而言，較穩妥的做法，是先把它作為一個穩定的公開基線；後續若要加入更精細的機制，也必須在相近的證據邊界下完成公開說明。

9. 結論

A-CSM 的正式標題為 *AI Contextual Signal Matrix*。在目前 GitHub 上傳資料夾中，`v0.1.0` 是一套具決定性、可本地運行、用於互動後對話語境風險審查的公開核心系統。這個版本的價值，在於讓公開核心可以被閱讀、重跑、審查，並且可以用目前公開套件內的文件與驗證結果自行核對。

A. 代表性指令

```
npm run lint:syntax
npm test
npm run test:coverage
npm run performance:baseline
npm run security:scan
npm run audit:workspace
npm run input:check -- \
  --input config/input-contract-input.sample.md \
  --config config/input-contract-config.sample.yaml \
  --output logs/input-contract-result.json \
  --format both
npm run acsm:run -- \
  --input config/acsm-orchestrator-input.sample.json \
  --config config/acsm-orchestrator.json \
  --validation config/validation-runner-result.sample.json \
  --output logs/acsm-orchestrator-result.json \
  --format both
npm run acsm:run:200
npm run regression:check
```

B. 參考文獻

References

[1] J. Au Yeung, J. Dalmasso, L. Foschini, R. J. B. Dobson, and Z. Kraljevic, “The Psychogenic Machine: Simulating AI Psychosis, Delusion Reinforcement and Harm Enablement in Large Language Models,” *arXiv preprint arXiv:2509.10970*, 2025.

[2] M. Chandra, S. Naik, D. Ford, E. Okoli, M. De Choudhury, M. Ershadi, G. Ramos, J. Hernandez, A. Bhattacharjee, S. Warreth, and J. Suh, "From Lived Experience to Insight: Unpacking the Psychological Risks of Using AI Conversational Agents," *arXiv preprint arXiv:2412.07951*, 2024.

[3] ZON RZVN, "The Seven Core Dimensions of Conversational Context (CXC-7): A Theoretical Framework Proposal," Zenodo, 2025 年 10 月。DOI：https://doi.org/10.5281/zenodo.18615646。

[4] ZON RZVN, "CXOD-7 and Coh(G): A Contextual Offense and Defense Evaluation Framework for AI Safety," Zenodo, 2025 年 10 月。DOI：https://doi.org/10.5281/zenodo.17403793。

[5] European Parliament and Council of the European Union, "Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)," 2024.

[6] International Organization for Standardization and International Electrotechnical Commission, "ISO/IEC 42001:2023 Information Technology - Artificial Intelligence - Management System," 2023.

[7] J. Moore, A. Mehta, W. Agnew, J. R. Anthis, R. Louie, Y. Mai, P. Yin, M. Cheng, S. J. Paech, K. Klyman, S. Chancellor, E. Lin, N. Haber, and D. Ong, "Characterizing Delusional Spirals through Human-LLM Chat Logs," *arXiv preprint arXiv:2603.16567v1*, 2026.

[8] National Institute of Standards and Technology, "Artificial Intelligence Risk Management Framework (AI RMF 1.0)," 2023.

[9] ZON RZVN, "User-Side Contextual Hallucination in Human-AI Interaction: A Framework Built Upon the CXC-7 and CXOD-7 Conversational Context Models," SSRN, 2026 年 1 月。DOI：https://doi.org/10.2139/ssrn.6135732。

[10] ZON RZVN, "User-Side Contextual Interaction Assessment (USCI): Methodology Specification Document," Zenodo, 2026 年 2 月。DOI：https://doi.org/10.5281/zenodo.18678458。